Universidad EAFIT

Laboratorio: Instalar un clúster EMR versión 6.14.0 Hadoop/Spark
Fecha: 2 noviembre 2023

Parte 1: Crear un clúster AWS EMR versión 6.14.0

1 Instalar AWS EMR

1. Buscar el servicio AWS EMR: Entrar a la consola web de AWS y buscar el servicio EMR:

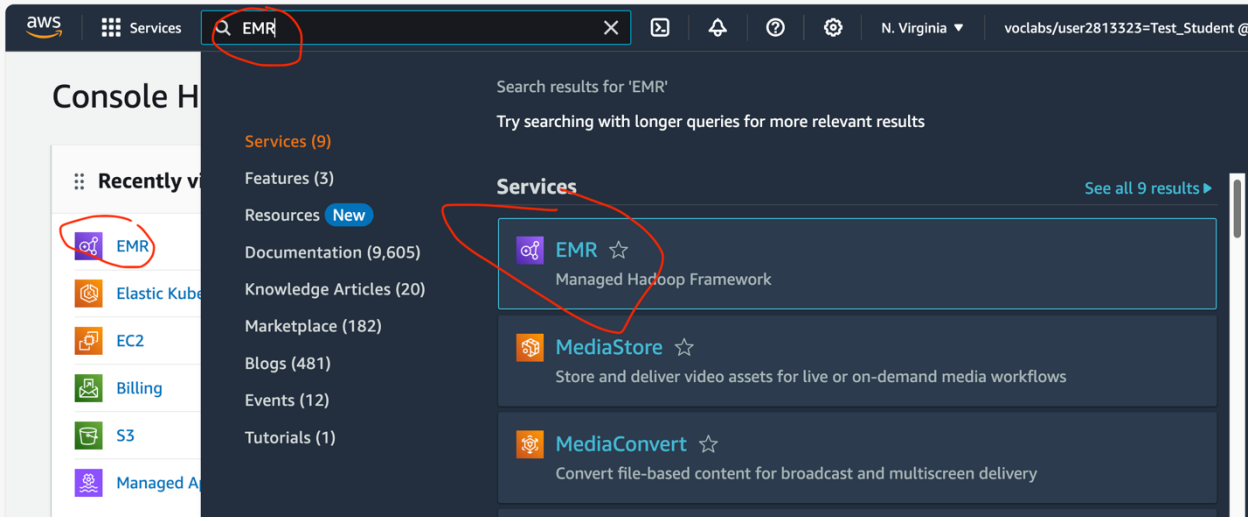

2. crear clúster

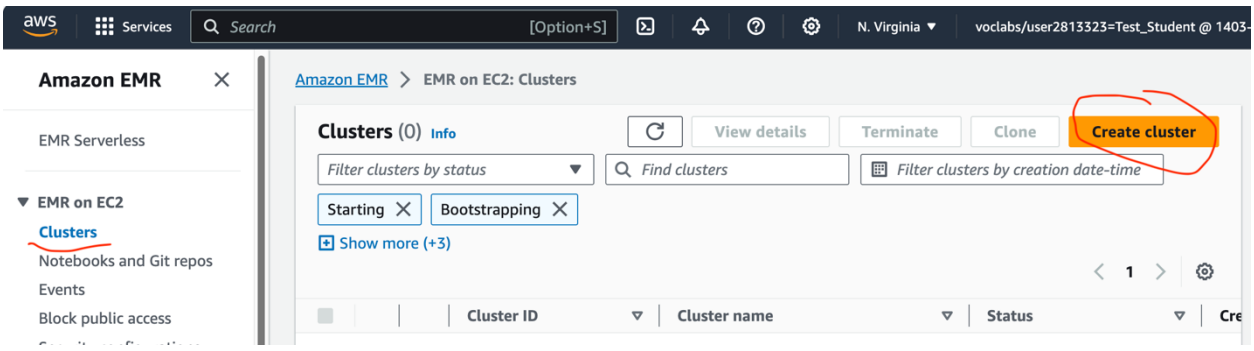

3. nombre, versión y Custom

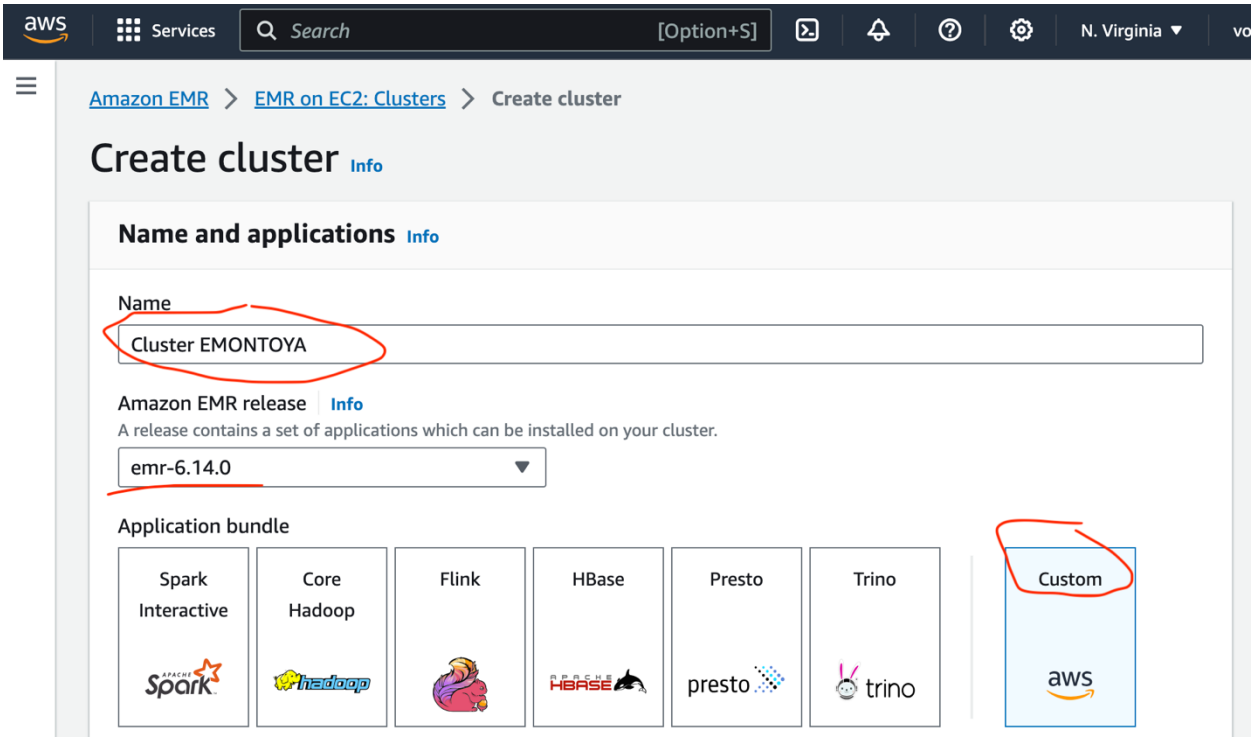

4. seleccionando los paquetes adecuados para el curso y activando los catálogos Glue, Hive, Spark

Nota: seleccionar los catalogos Hive y Spark permite ver las tablas AWS Glue en EMR, y las tablas Hive se podrán ver en Glue / Athena.

Seleccione los paquetes hadoop/Spark en azul.

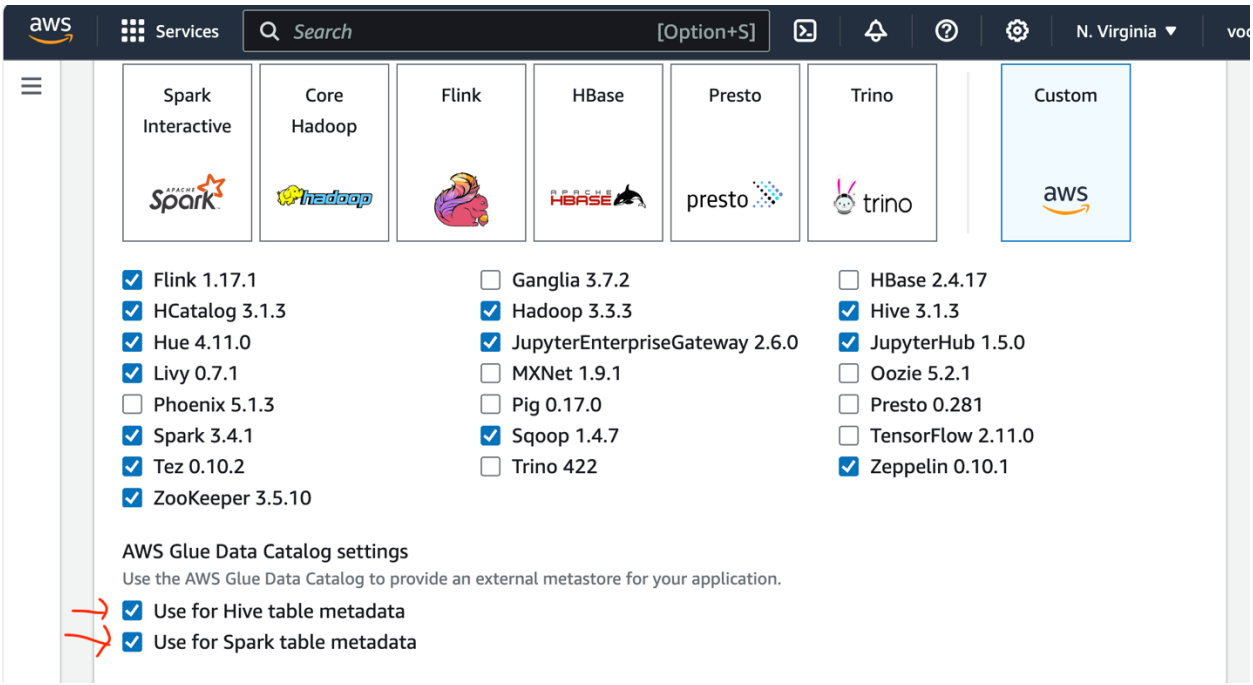

5. Máquinas EC2 del Clúster

Puede dejar las máquinas por defecto m5.xlarge, en algunos momentos puede fallar la creación del clúster porque no tiene suficientes recursos, puede cambiar estas máquinas a m4.xlarge, pero por defecto dejarlas como nos sugiere la creación del clúster EMR.

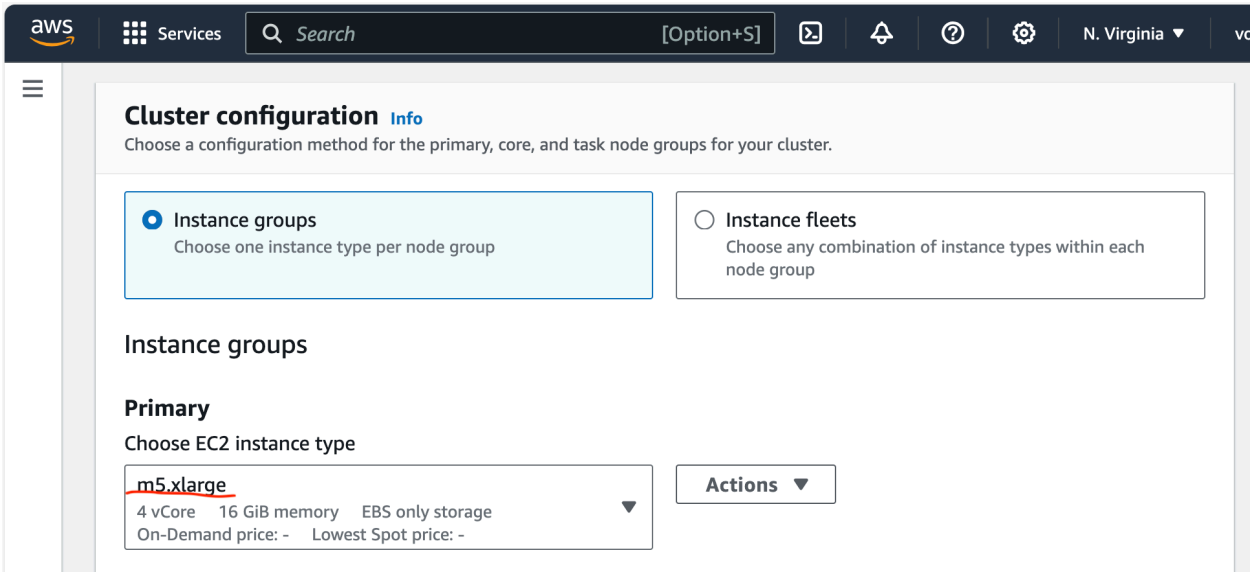

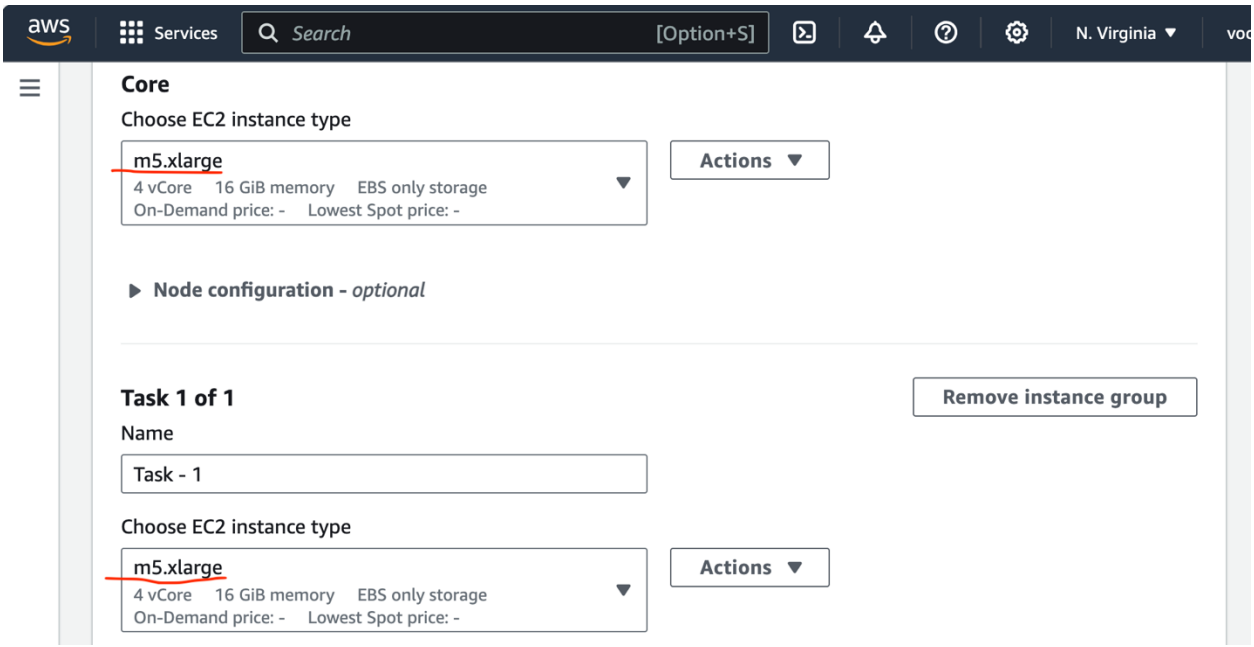

6. Dejar estas opciones por defecto

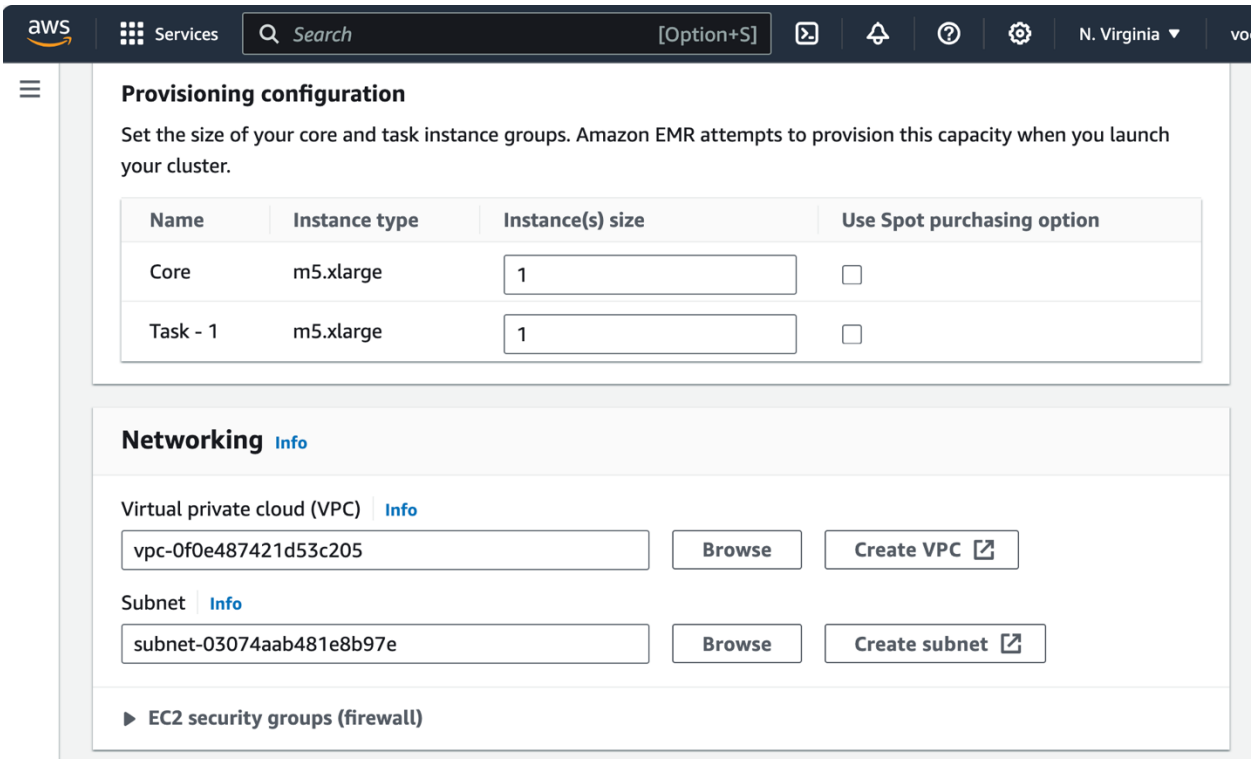

Dejar las siguientes opciones por defecto hasta: Software settings.

7. Configurar software settings

Acá va a configurar el bucket para guardar los notebooks jupyter y no se pierdan cuando se borre el clúster EMR.

Realizar una búsqueda sencilla Google: aws emr jupyterhub s3

Nos conduce al enlace: https://docs.aws.amazon.com/emr/latest/ReleaseGuide/emr-jupyterhub-s3.html

Configurar con tu propio bucket (crear un bucket para esto)

Antes:

```
[
  {
    "Classification": "jupyter-s3-conf",
    "Properties": {
      "s3.persistence.enabled": "true",
      "s3.persistence.bucket": "MyJupyterBackups"
    }
  }
]
```

Con mi bucket:

```
[
  {
    "Classification": "jupyter-s3-conf",
    "Properties": {
      "s3.persistence.enabled": "true",
      "s3.persistence.bucket": "emontoyanotebooks"
    }
  }
]
```

Y pegue esta configuración en Software Settings así:

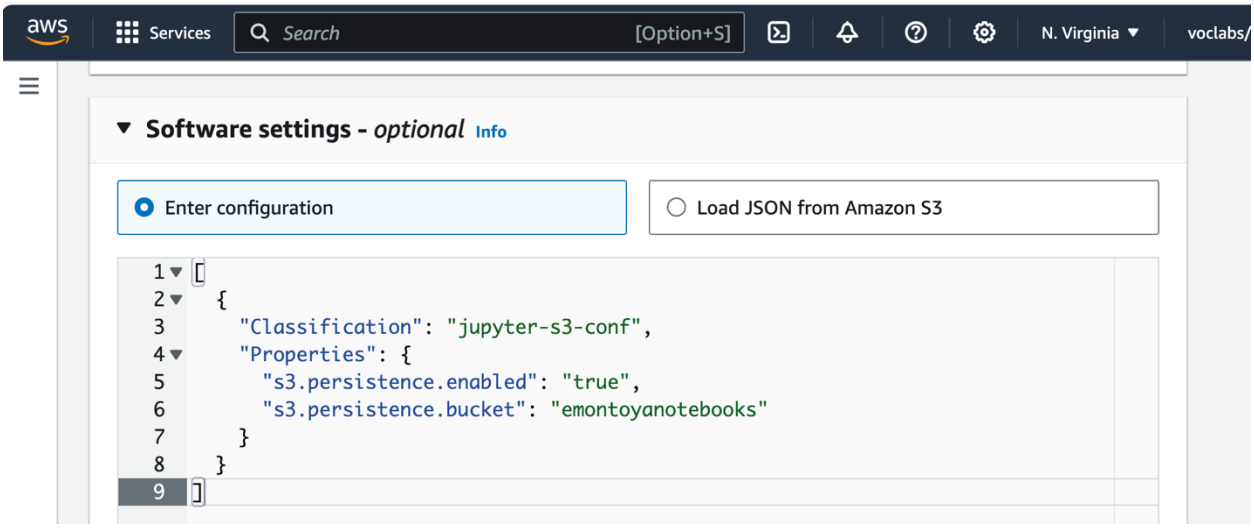

8. Security configuration and EC2 key pair

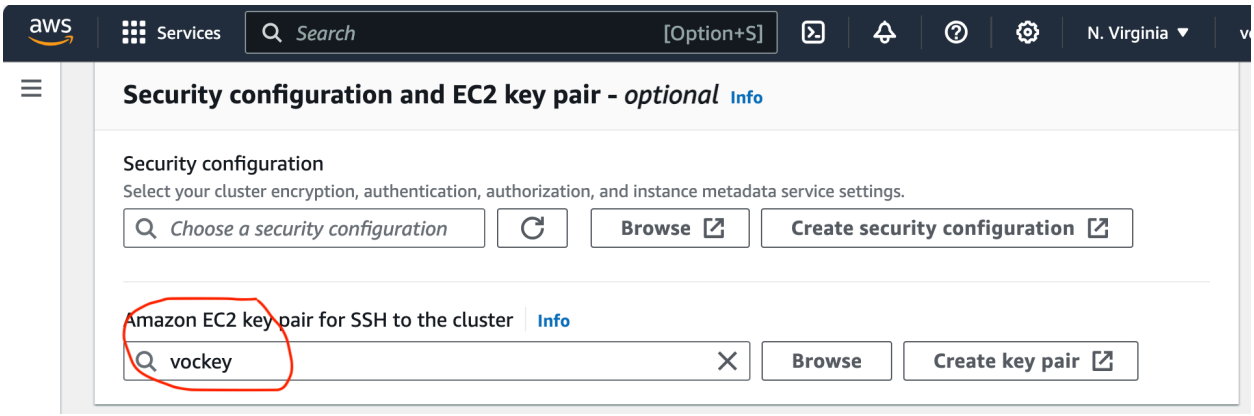

9. IAM roles

Debe seleccionar:

Service role: EMR_DefaultRole
Instance profile: EMR_EC2_DefaultRole
Custom automatic scaling role: LabRole

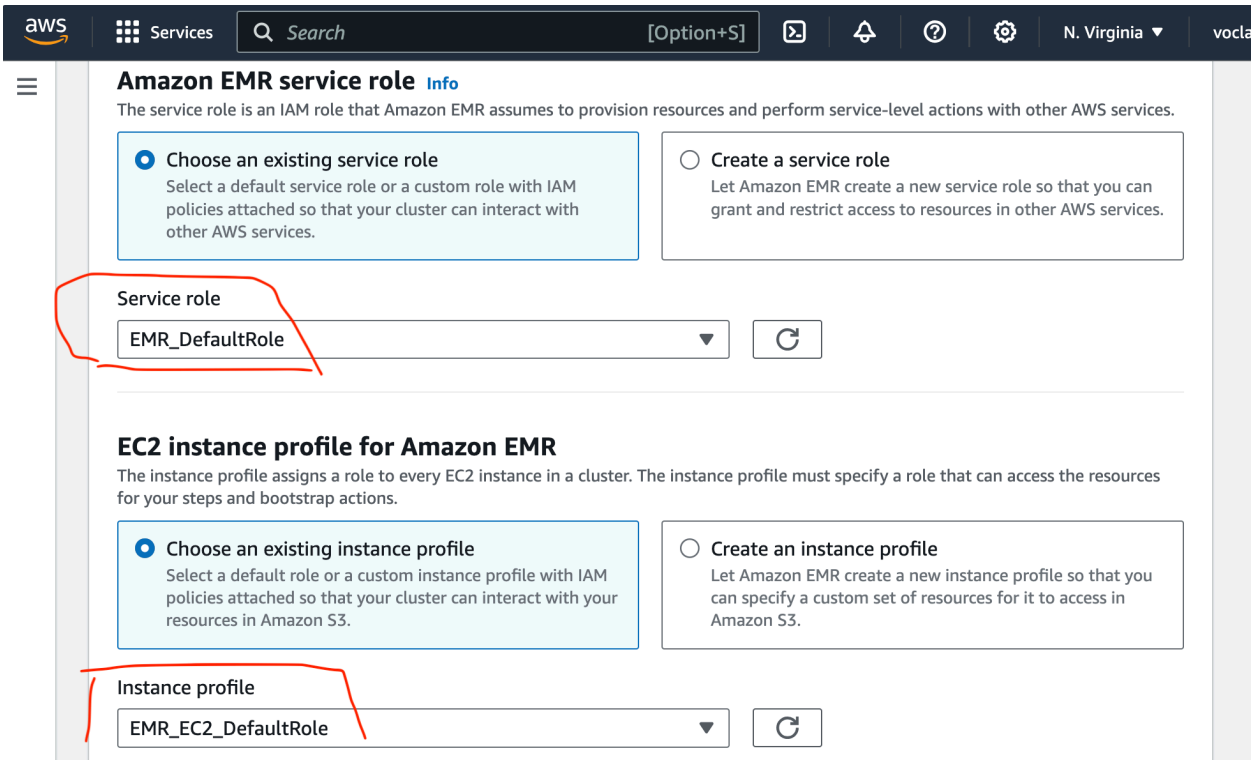
aws
Services
Search
[Option+S]
N. Virginia
Amazon EMR service role Info
The service role is an IAM role that Amazon EMR assumes to provision resources and perform service-level actions with other AWS services.
Choose an existing service role
Select a default service role or a custom role with IAM policies attached so that your cluster can interact with other AWS services.
Create a service role
Let Amazon EMR create a new service role so that you can grant and restrict access to resources in other AWS services.
Service role
EMR_DefaultRole
EC2 instance profile for Amazon EMR
The instance profile assigns a role to every EC2 instance in a cluster. The instance profile must specify a role that can access the resources for your steps and bootstrap actions.
Choose an existing instance profile
Select a default role or a custom instance profile with IAM policies attached so that your cluster can interact with your resources in Amazon S3.
Create an instance profile
Let Amazon EMR create a new instance profile so that you can specify a custom set of resources for it to access in Amazon S3.
Instance profile
EMR_EC2_DefaultRole

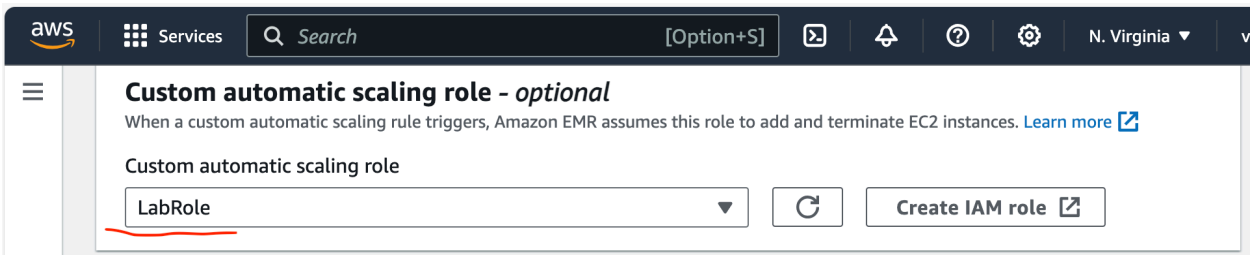
aws
Services
Search
[Option+S]
N. Virginia
Custom automatic scaling role - optional
When a custom automatic scaling rule triggers, Amazon EMR assumes this role to add and terminate EC2 instances. Learn more
Custom automatic scaling role
LabRole
Create IAM role

10. Finalmente, a crear el clúster

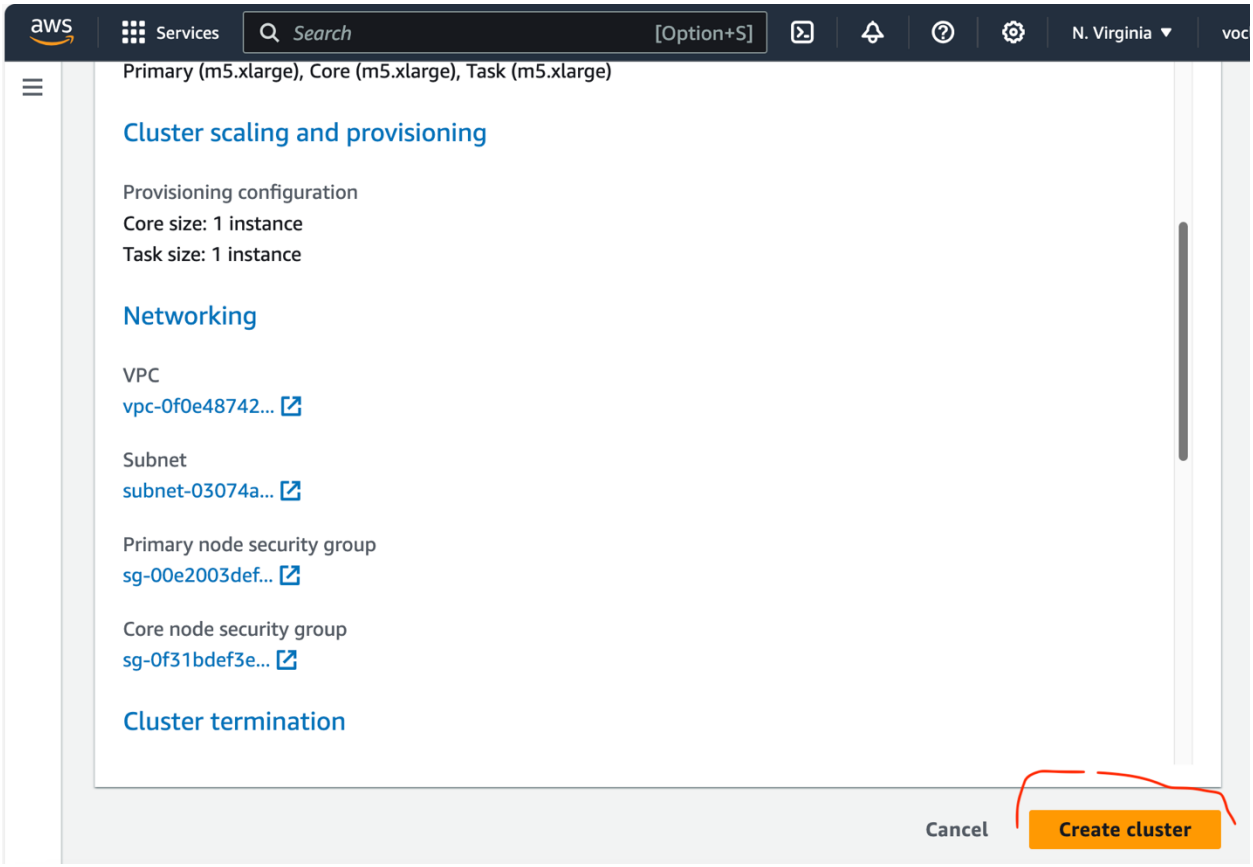

Este proceso demora aproximadamente 20 minutos, tenga paciencia.

Debe salir con este mensaje de clúster exitosamente creado:

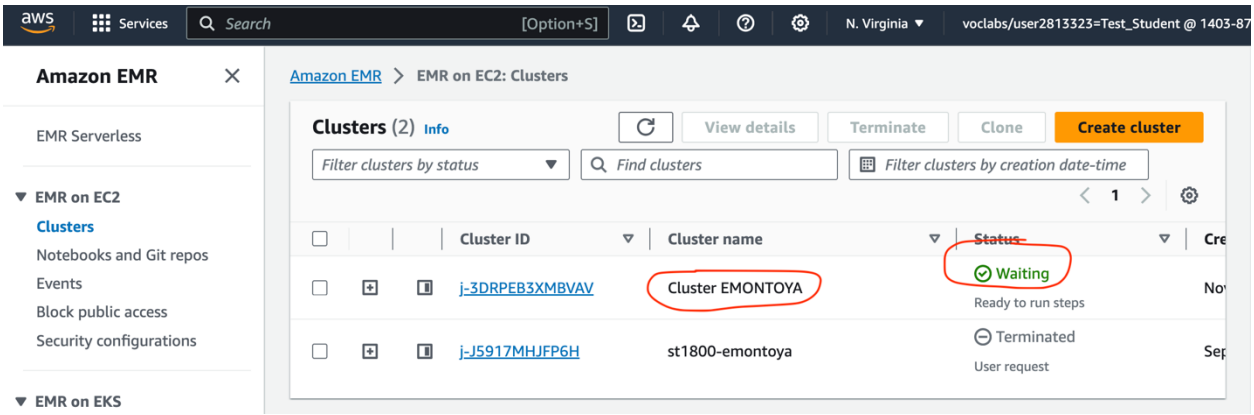

11. Debe abrir todos los puertos TCP para acceso al clúster así

(nota: esto solo se hace una vez, cada vez que crea, destruya o clone un clúster, ya quedan abiertos)

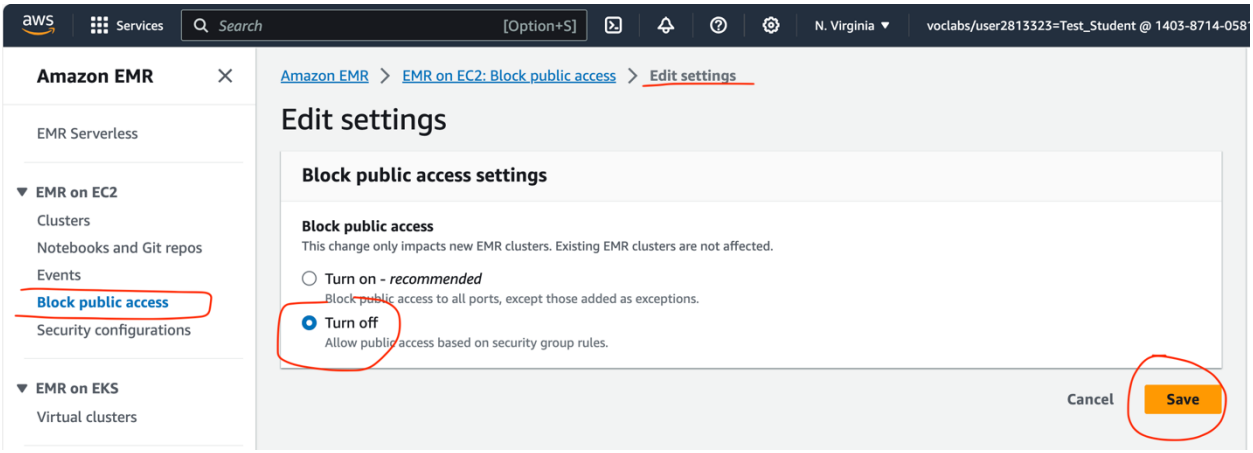

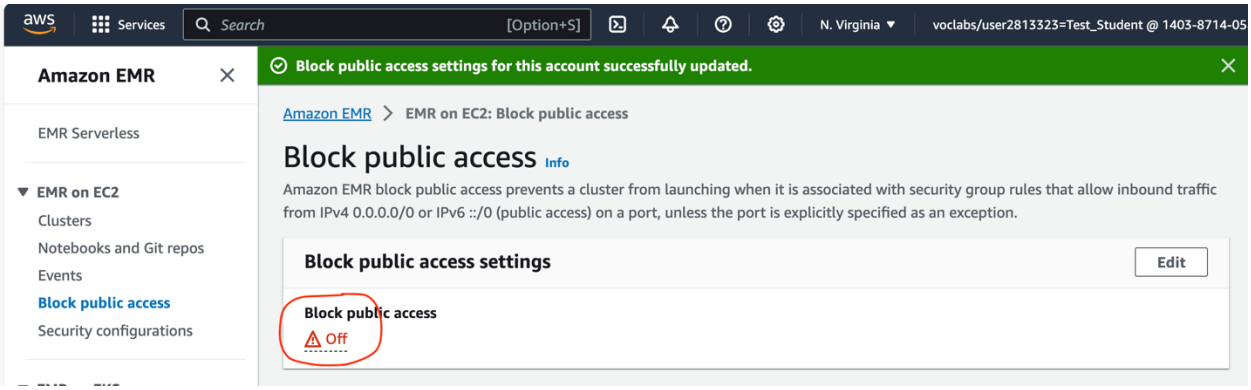

Tambien debe abrir los puertos de las aplicaciones de hadoop/Spark en el Security Group del nodo MASTER del cluster.

(nota: esto solo se hace una vez, cada vez que crea, destruya o clone un clúster, ya quedan abiertos)

Donde ubico el nodo master?

Dar Click en el cluster que acabas de crear, mirar la IP y nombre de la máquina EC2:

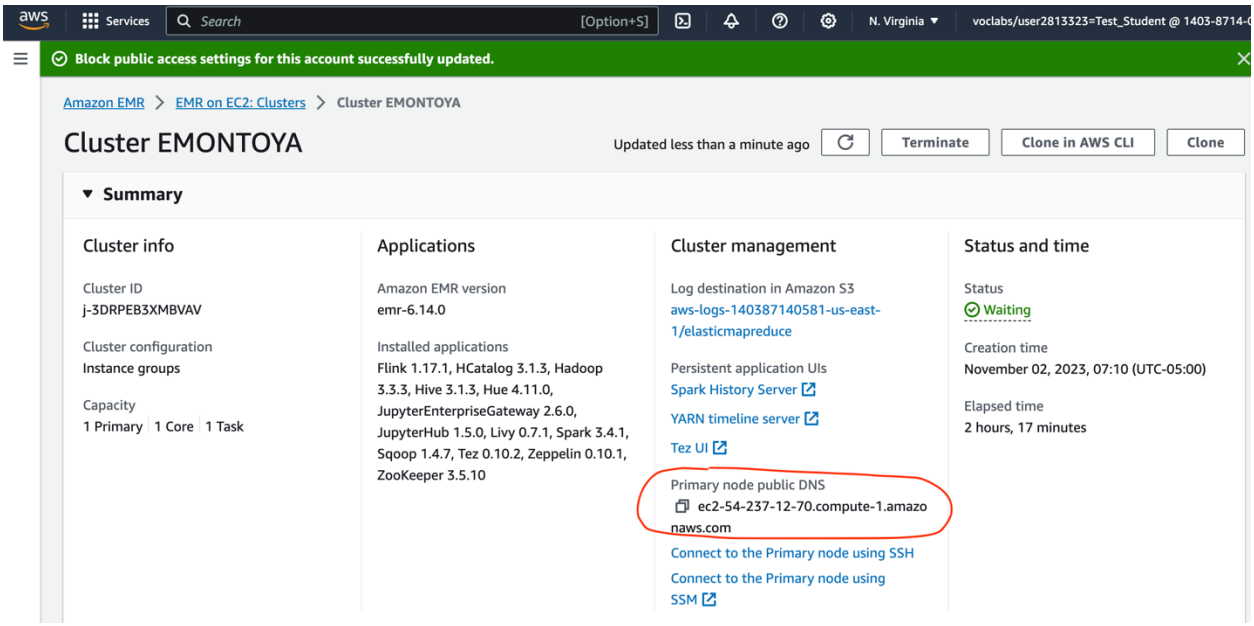

Luego entras al servicio EC2 de dicha máquina Master, y va a modificar el Security Group para agregar los siguientes puertos de las aplicaciones:

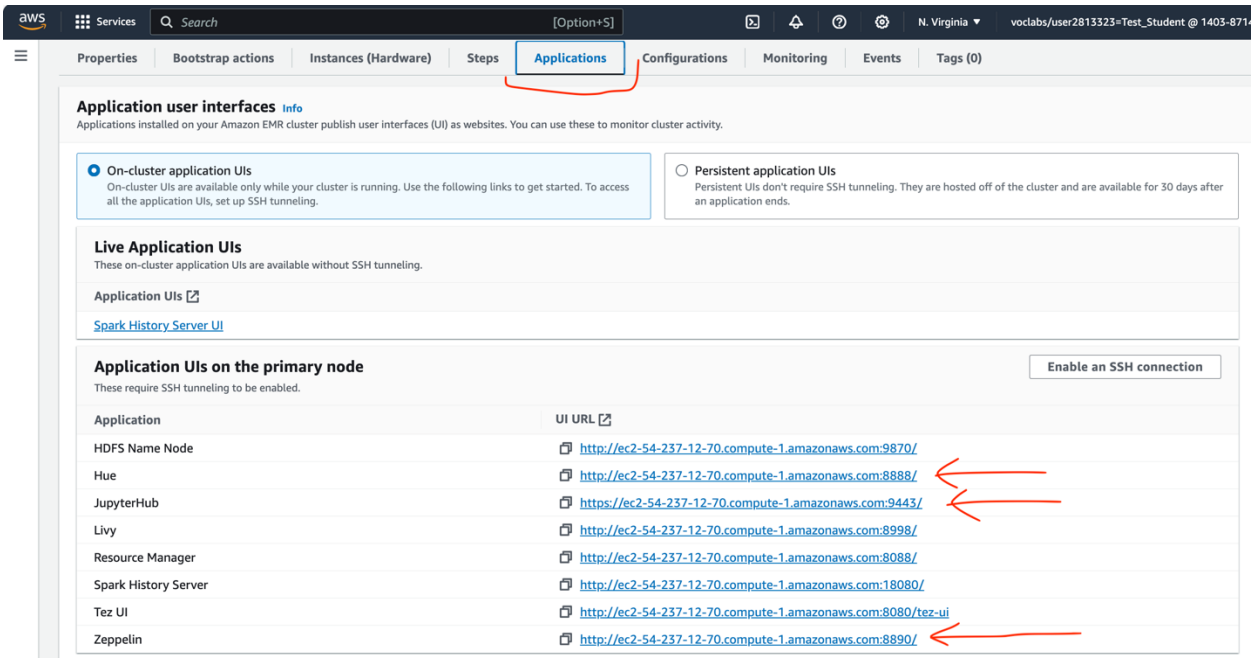

Además, abrir los puertos TCP:

22
14000
9870

En AWS EC2, les debería mostrar 3 máquinas:

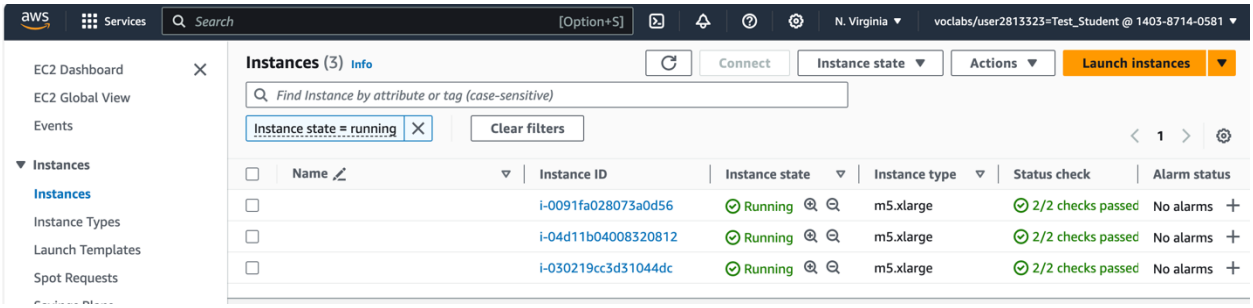

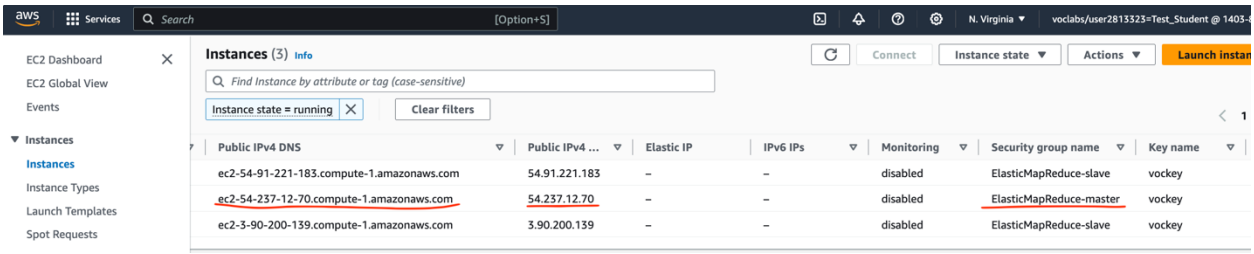

Entrar a la pestaña de seguridad de la Instancia EC2 del nodo master:

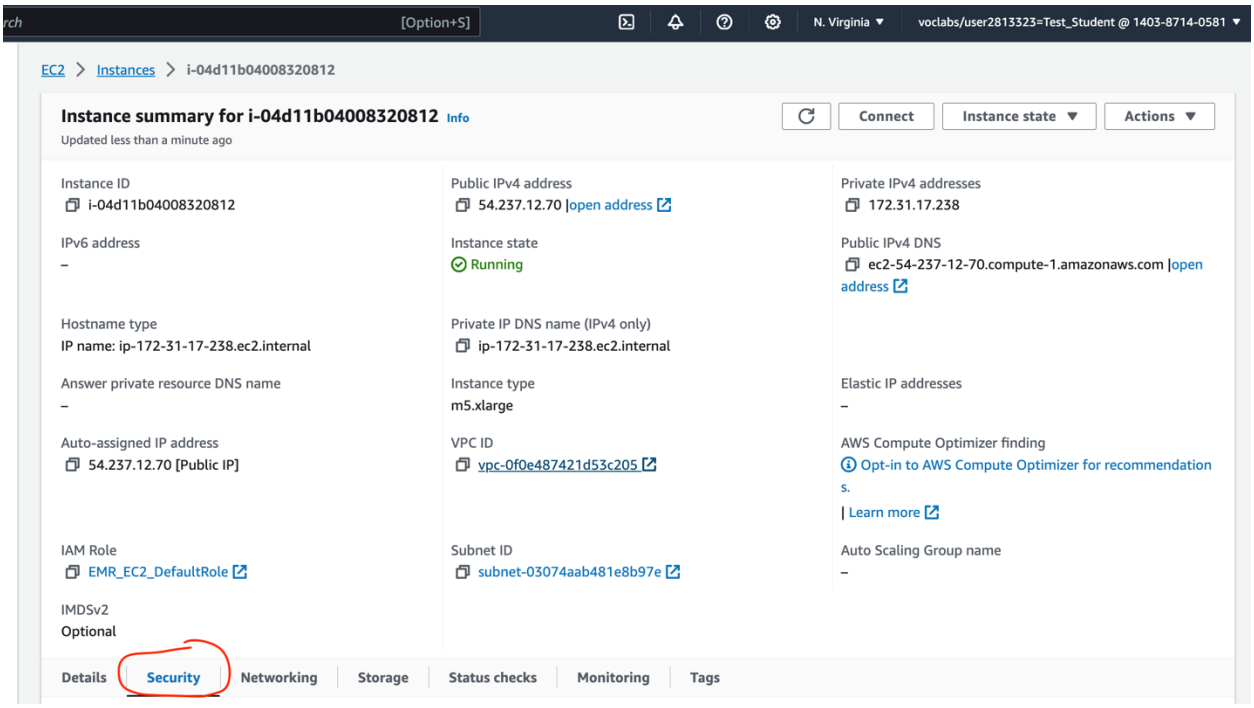

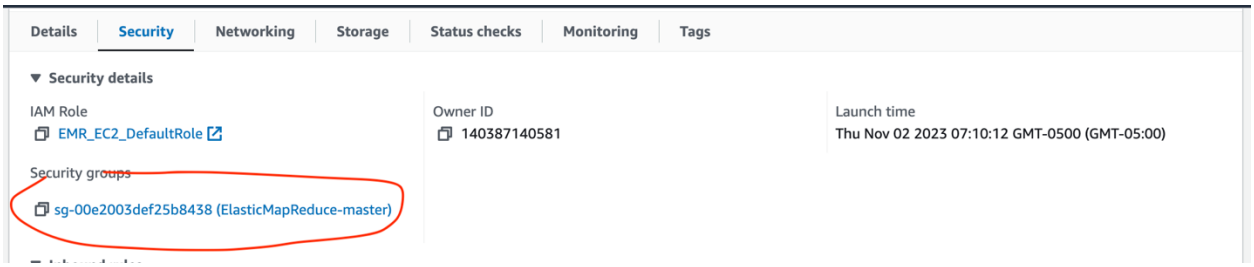

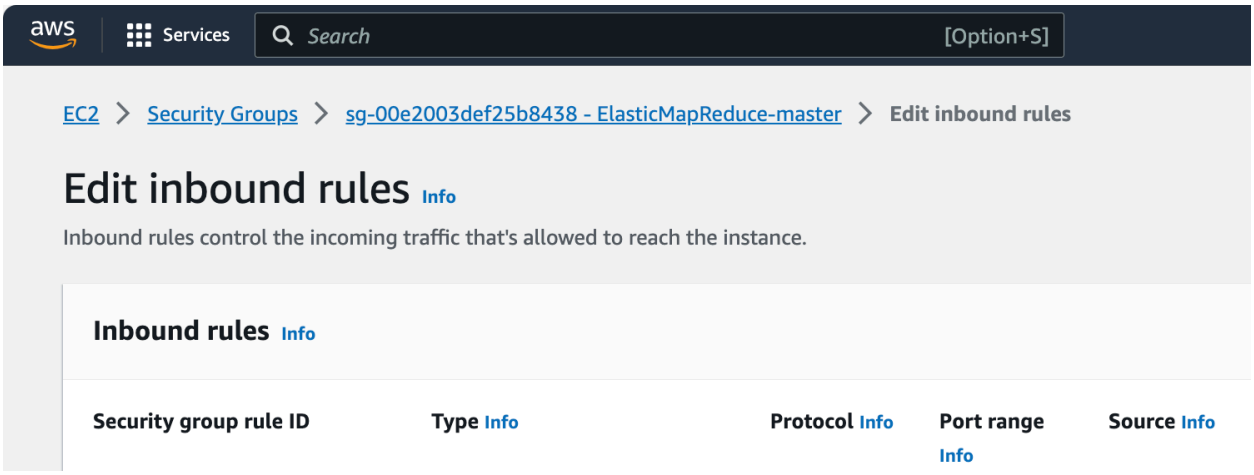

Uno a uno, va adicionando los puertos, aca se adiciono el puerto 22, haga lo mismo para los demás puertos:

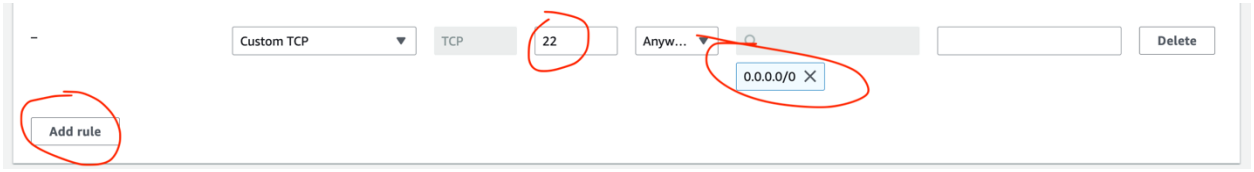

Parte 2: Borrar y recrear clúster

Los clúster EMR en amazon, son temporales.

Los clúster EMR no se pueden pausar

Cada que no requiera trabajar más con un clúster, DEBE BORRARLO:

Pero la próxima vez que lo requiera, puede Clonar y crear nuevamente un clúster, teniendo en cuenta la configuración de otro clúster previamente creado, esta es la opción que debe utilizar.

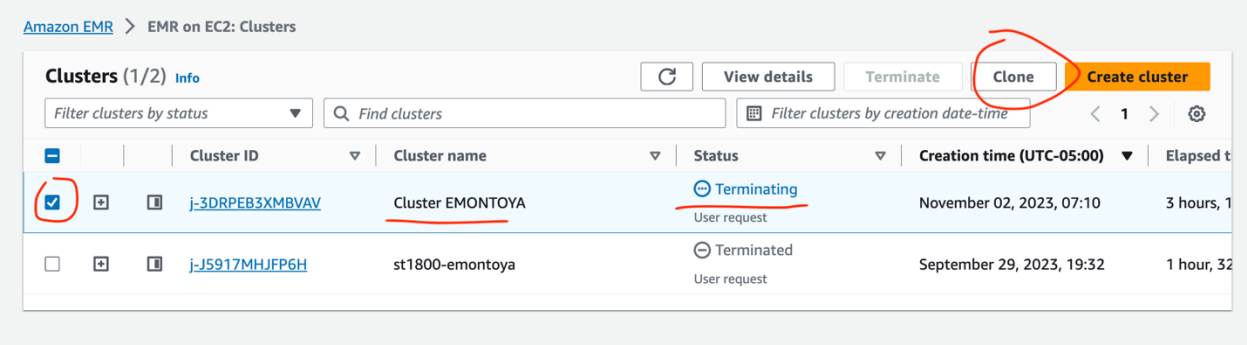

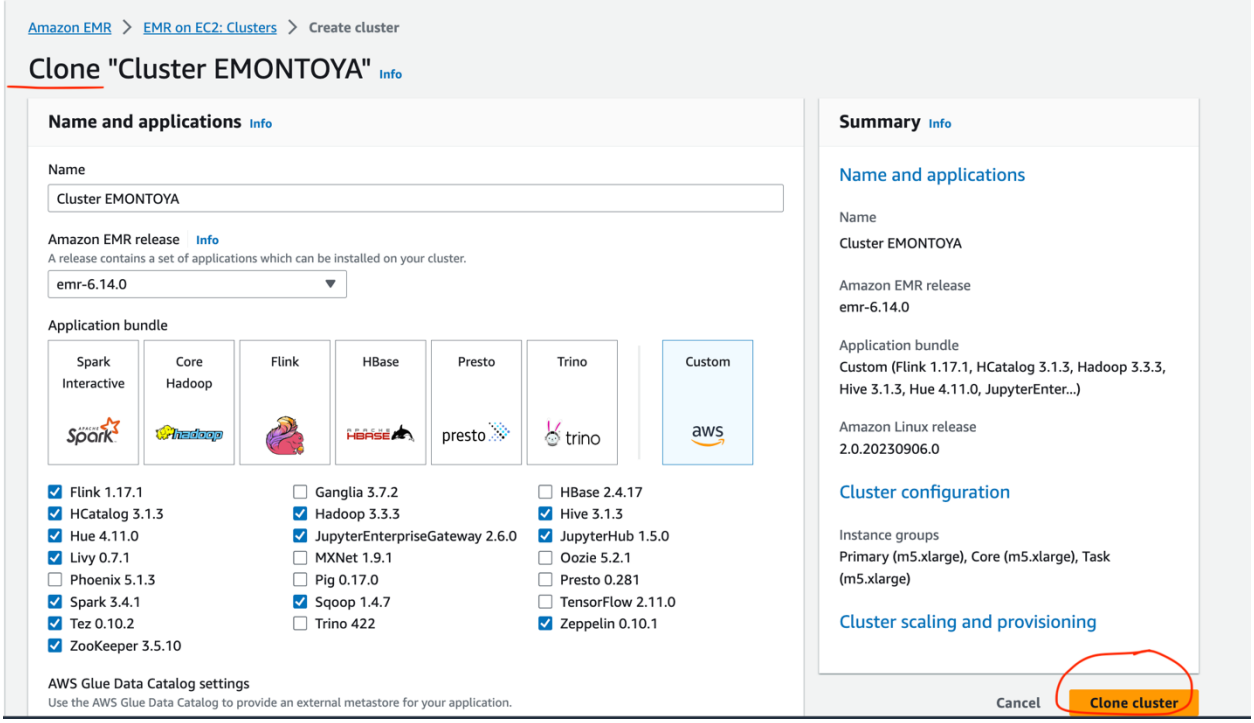

Cada vez que lo Clone, debe crear nuevamente el usuario hadoop / con su password de preferencia, así como realizar el arreglo del archivo hue.ini para cambiar el puerto 14000 a 9870 (esto lo entenderá más adelante)

Parte 3: Ingresar al clúster EMR por Hue

Utilice la aplicación hue, por el puerto 8888 desde un browser a la ip o nombre del nodo master.

Fijarse en la aplicación del clúster HUE:

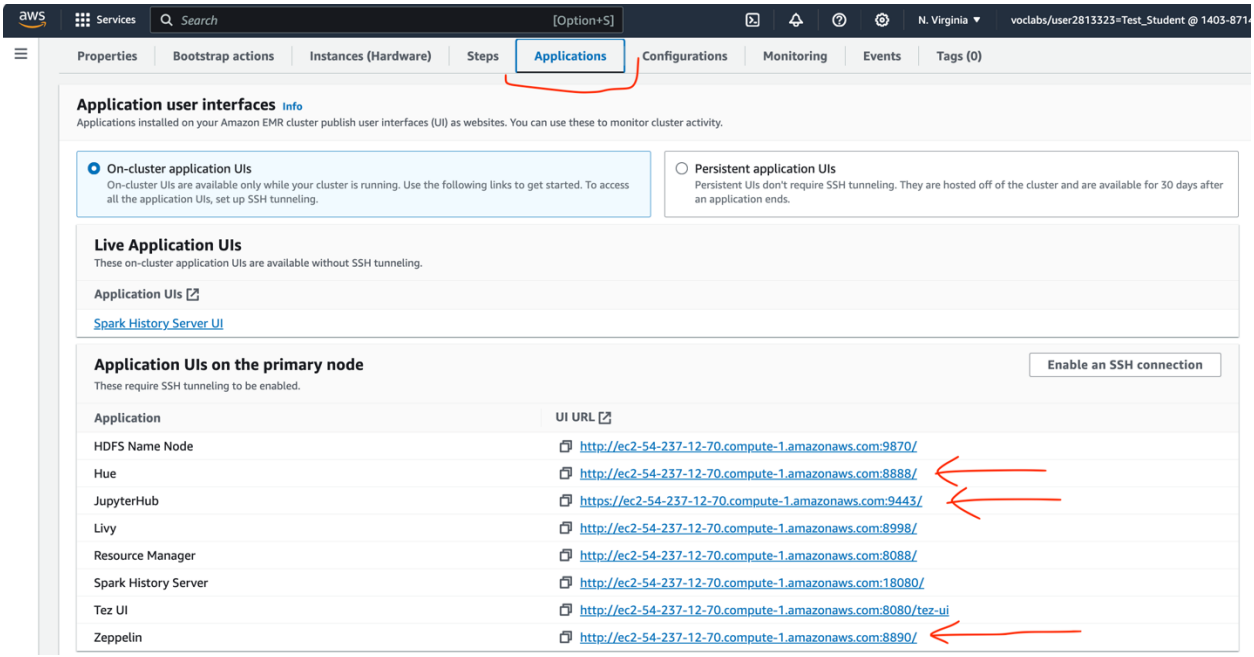

Y darle click a la URL de HUE, en este ejemplo:

http://ec2-54-237-12-70.compute-1.amazonaws.com:8888

La primera vez, me pide crear un usuario y clave:

Username: hadoop
Passoword: <<el que quiera>>

Nota: el usuario tiene que ser ‘hadoop`

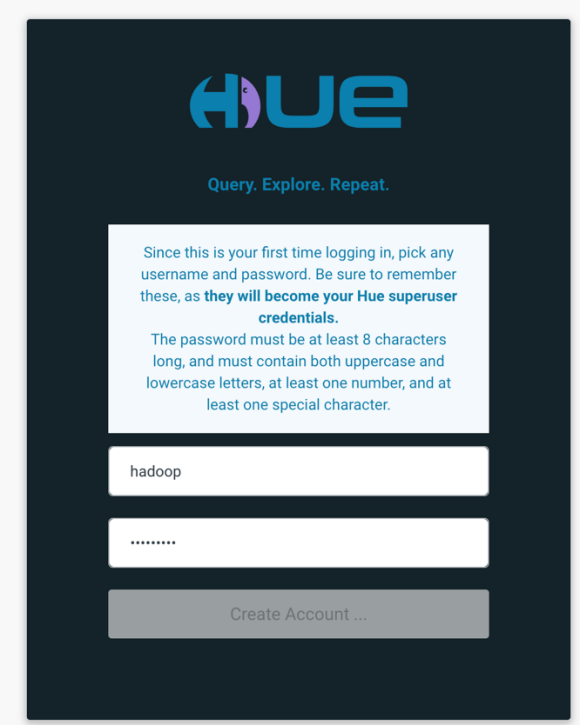

Deberá salir una interfaz así:

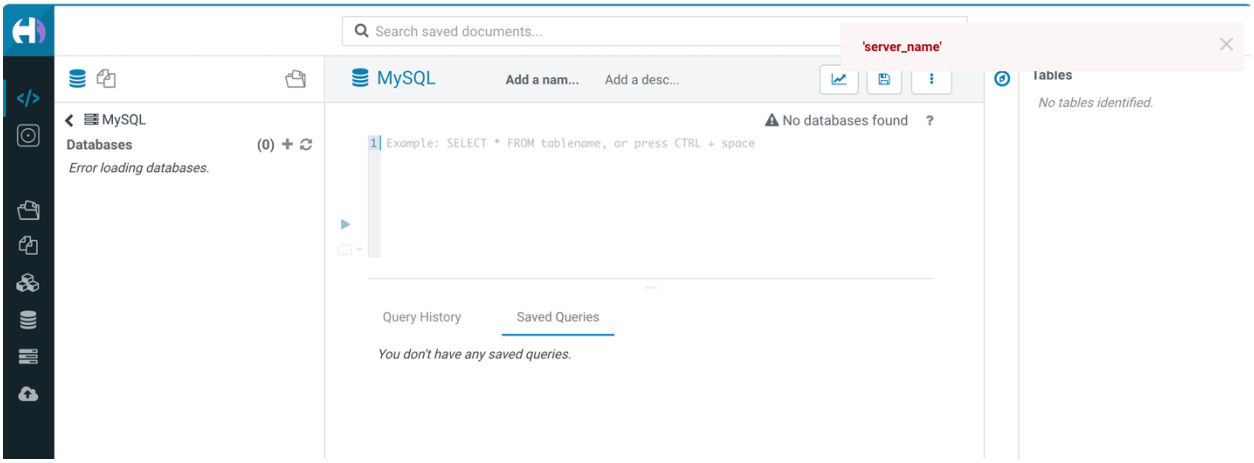

Podrá acceder los servicios Hive, Spark, S3, pero el servicio de Files (archivos) HDFS falla, y le saldrá un error así:

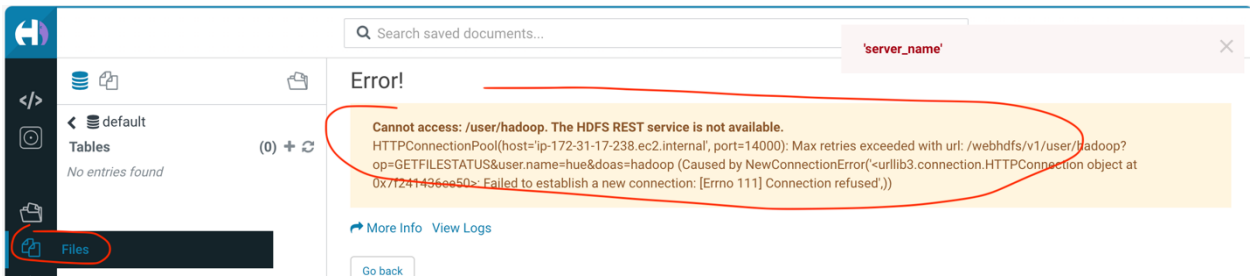

Esto se corrige, entrando por SSH al nodo master del clúster, y realizando esto:

a. Entrar al EC2 nodo master por SSH

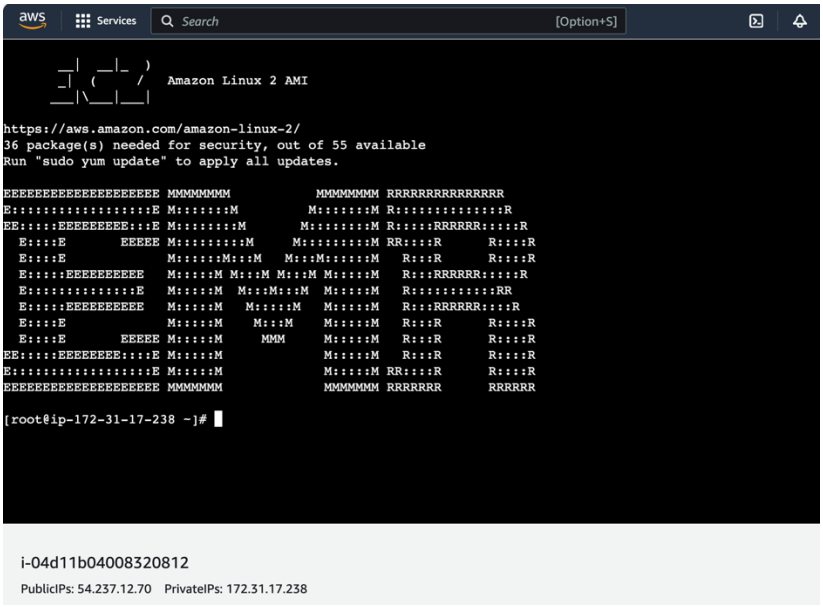

b. Editar el archivo hue.ini

nano /etc/hue/conf/hue.ini

buscar la línea que contenga: ‘webhdfs-url’ y cambiar el puerto de 14000 a 9870

(en nano puede utilizar control-w para buscar la palabra)

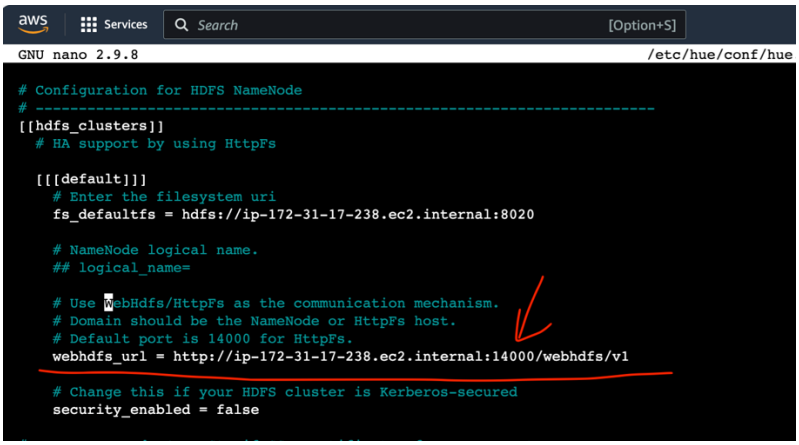

Cambiado y salvado:

(para salvar en nano: control-x -> Y para yes)

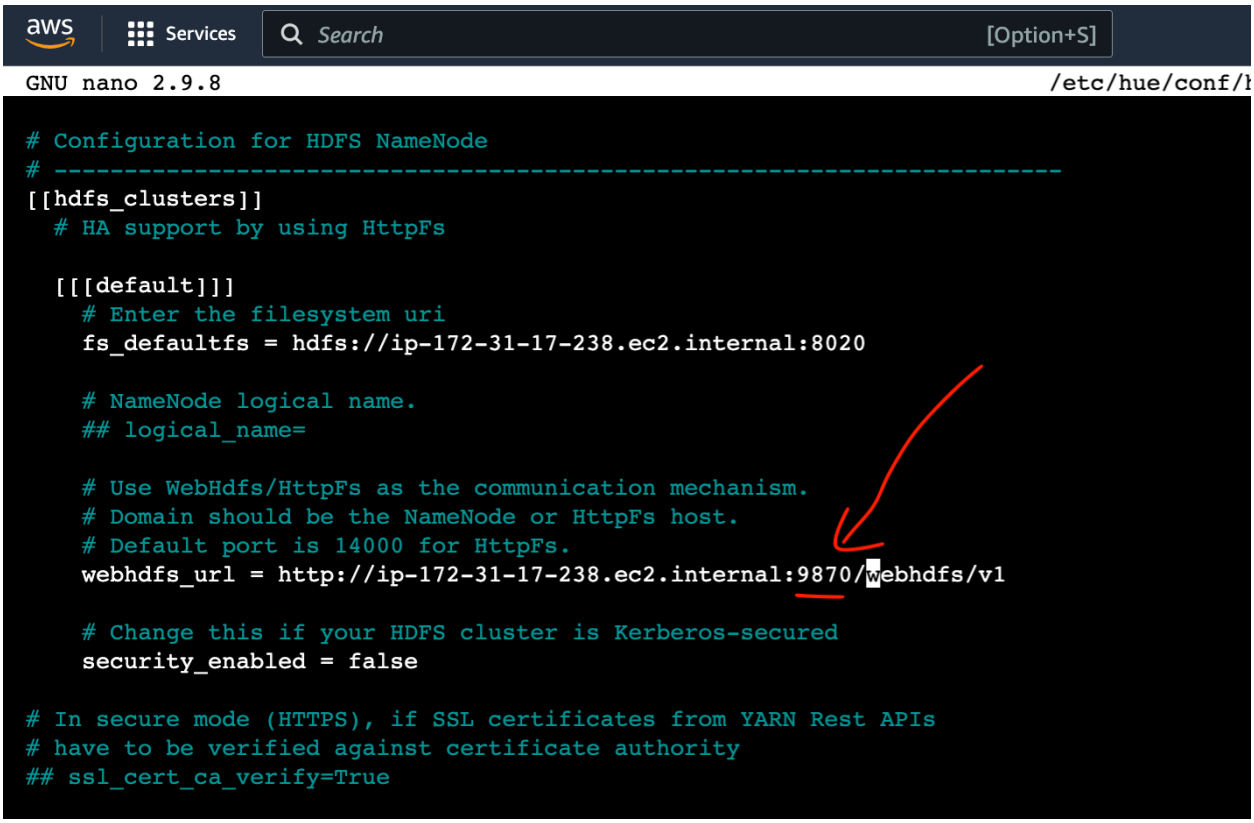

c. Reiniciar el servicio hue

systemctl restart hue.service

Listo!!!!!! Ya puede entrar nuevamente por hue:

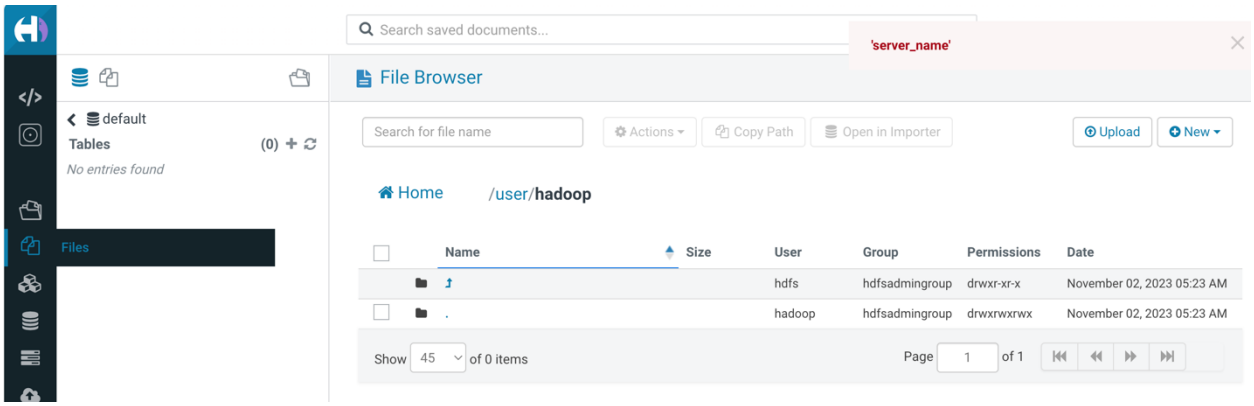

Ya va a poder gestionar archivos sin problema por hue para HDFS

Parte 4: entrar a jupyter hub

Utilice la aplicación jupyterhub de:

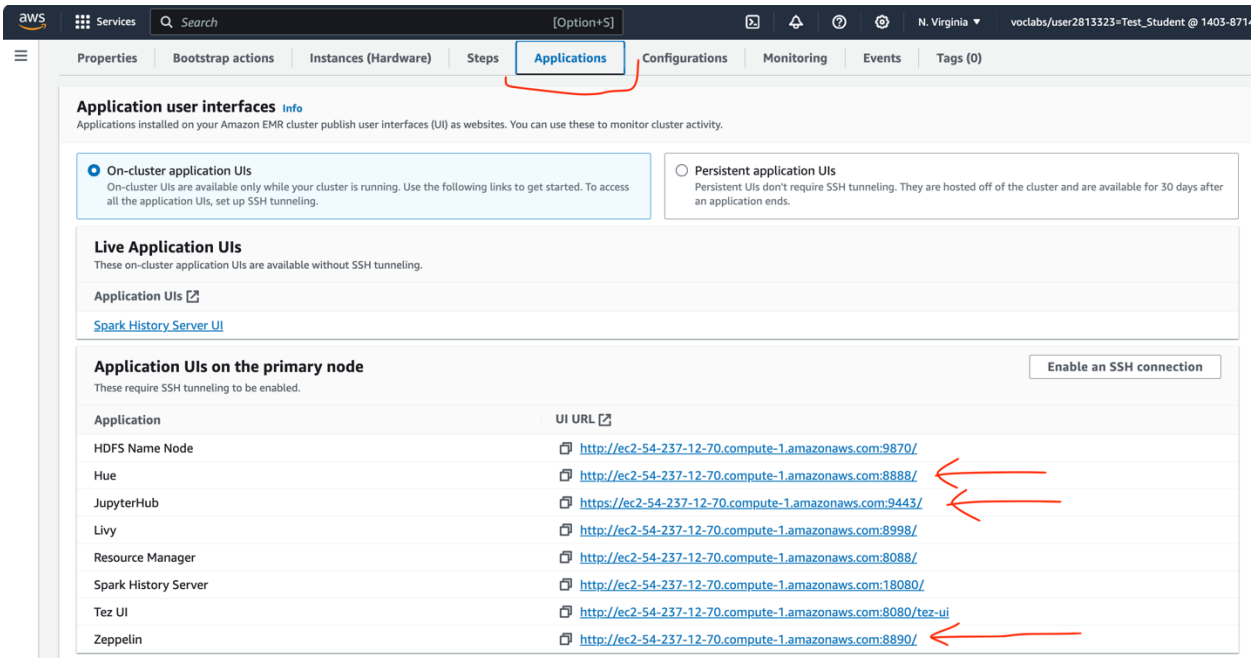

Para este caso la URL es: https://ec2-54-237-12-70.compute-1.amazonaws.com:9443/

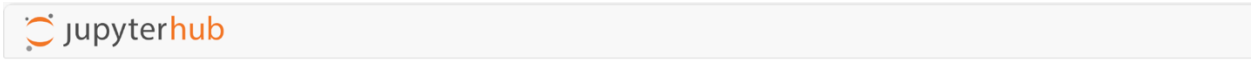

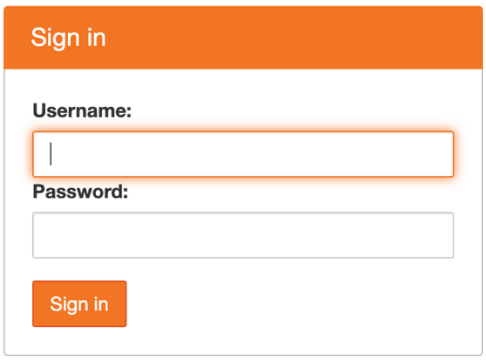

Utilice el usuario por defecto:

Username: `jovyan`
Password: `jupyter`

Tomado de: https://docs.aws.amazon.com/emr/latest/ReleaseGuide/emr-jupyterhub-user-access.html

Y listo, ya puede realizar notebooks pyspark, verifique que las 2 variables más importantes de contexto de spark esta activas en un notebook así: (primero debe crear un notebook pyspark)